

Prédiction de Souscription Client

Bank Marketing Dataset · UCI Machine Learning Repository

Régression Logistique · Random Forest · CNN 1D

DIOP Mouhamed , DIALLO Samba

Moro et al. (2014). Decision Support Systems, 62, 22-31.

5 000

instances

20

features

2

classes

7,7 %

taux souscription

Quel problème cherche-t-on à résoudre ?

Une banque portugaise contacte ses clients par téléphone pour leur proposer un dépôt à terme. L'objectif est de prédire si un client va souscrire.

Objectif

Prédire $y \in \{0, 1\}$ à partir de 20 variables.
Classification binaire.

Classification binaire · Variable cible : $y \in \{0, 1\}$

Client

âge, métier, situation familiale,
éducation, crédit immobilier, prêt

Campagne

durée appel, mois, type de contact,
nombre de contacts, résultat précédent


Économique

Euribor 3 mois, taux emploi,
indice de confiance consommateurs


20 variables · 5 000 instances · aucune valeur manquante

Les données révèlent déjà beaucoup

Distribution des classes




Durée d'appel selon la décision



Gauche : fort déséquilibre (92,3 % non-souscription). Droite : les souscripteurs ont une durée d'appel médiane sensiblement plus longue (415 s vs 258 s).

Tous les profils ne se ressemblent pas

Taux de souscription par métier



Les retraités et étudiants ont les taux de souscription les plus élevés. Le métier est une variable utile pour cibler les campagnes.

Pipeline de préparation des données

1

Label Encoding

10 variables
catégorielles
→ entiers

2

Train / Test

80 % train
20 % test
stratifié

3

SMOTE

Synthèse de la
classe minoritaire
sur le train set

4

StandardScaler

Centrage-réduction
 $\mu = 0$, $\sigma = 1$
fit sur train

⚠ *SMOTE est appliqué uniquement sur le train set — le test set conserve la distribution réelle (7,7 % vs 92,3 %)*

Trois approches complémentaires

Régression Logistique

Modèle de référence

Modèle linéaire interprétable.
Modélise $P(y=1 | x)$ via la fonction sigmoïde.

Paramètres :
class_weight = balanced
max_iter = 1 000
solver = lbfgs

Random Forest

Apprentissage d'ensemble

100 arbres de décision entraînés sur des sous-échantillons (bagging).
Votes majoritaires.

Paramètres :
100 estimateurs
max_depth = 10
class_weight = balanced

CNN 1D


Deep Learning

Convolutions 1D sur les features réinterprétées comme séquence.

Architecture :
Conv1D(64) → Conv1D(32)
GlobalAvgPool → Dense(64)
Dropout(0.3) → Sigmoid
30 epochs · batch 64

Qui détecte vraiment les clients intéressés ?


Matrices de Confusion — Comparaison des 3 modèles



La Régression Logistique détecte 32 vrais positifs (Recall 41,6 %) — bien plus que la Random Forest (13) ou le CNN (7).

Pouvoir discriminant global

Courbes ROC — Comparaison des 3 modèles



Random Forest

AUC = 0,640

Meilleure courbe — la plus éloignée de la diagonale.

Régression Log.

AUC = 0,602

Bon recall malgré une AUC moindre.

CNN 1D


AUC = 0,546

Proche de l'aléatoire — courbe orange collée à la diagonale.

Récapitulatif des performances



Modèle	Accuracy	Precision	Recall	F1	AUC
Régression Log.	73,3 %	12,6 %	41,6 %	19,3 %	0,60
Random Forest	83,1 %	11,0 %	16,9 %	13,3 %	0,64
CNN 1D	85,0 %	8,1 %	9,1 %	8,5 %	0,55

Valeurs en vert = meilleur résultat sur ce critère



Le CNN converge — mais sans avantage réel

Courbes d'apprentissage — CNN 1D



Pas d'overfitting

La val_loss converge
stablement vers l'époque 15.
Le modèle généralise.

AUC proche du hasard

AUC = 0,55. Les CNN
traitent des séquences —
structure absente ici.

Ce qui a marché — ce qui n'a pas marché

Ce qui a bien fonctionné

- SMOTE : recall amélioré de ~15 % à 41 % sur la Régression Logistique
- `class_weight='balanced'` efficace à coût quasi nul
- Random Forest : meilleure AUC (0,64) et feature importance exploitable
- Pipeline reproductible — aucun data leakage détecté

Ce qui n'a pas fonctionné

- CNN peu adapté aux données tabulaires (AUC = 0,55)
- Précision classe 1 faible (8-13 %) malgré le SMOTE
- Absence d'optimisation systématique des hyperparamètres
- Dataset simulé — à valider sur les 41 k instances UCI

Conclusion

Régression Logistique

Recall 41,6 %

Recommandé pour
la détection de prospects

Random Forest

AUC 0,640

Recommandé pour
le scoring et la segmentation

CNN 1D

Acc. 85,0 %

Moins adapté —
données sans structure séq.

Point clé

Le déséquilibre 92/8 % est la difficulté centrale du projet. SMOTE l'atténue, mais le choix de la métrique (recall vs AUC) dépend de l'objectif métier. Prochaines étapes : XGBoost et ajustement du seuil de décision.